Alberi di Decisione per Intrusion Detection

Lorenzo Pesci

2 novembre 2018

1 Introduzione

Lo scopo di questo elaborato è quello di utilizzare diverse implementazioni di *Decision Trees* relativamente al problema dell'Intrusion Detection.

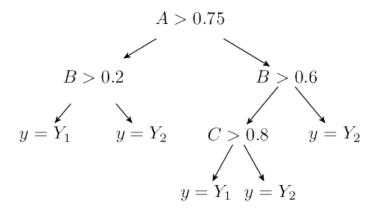


Figura 1: Un esempio di albero di decisione. [ce.unipr.it]

1.1 Alberi di Decisione

Nell'ambito del *Machine Learning* un metodo semplice ed efficace per risolvere problemi di classificazione è quello di utilizzare gli alberi di decisione.

Un albero di decisione, costruito a partire da un insieme di dati iniziali (dataset), è un albero in cui ogni nodo interno è associato ad una particolare "domanda" su una certa caratteristica dei dati. Da questo nodo escono tanti archi quanti sono i possibili valori che la caratteristica può assumere, fino a raggiungere le foglie che indicano la categoria associata alla decisione.

Lo scopo è quello di allenare questo albero su alcuni esempi di dati (training set) in modo da poter classificare altri dati non precedentemente visionati (test set) con un certo livello di confidenza.

Un problema comune con gli alberi di decisione è che spesso si adattano fin troppo bene ad alcune caratteristiche specifiche solo del training set, e questo porta ad un calo delle prestazioni sul test set.

1.2 Intrusion Detection

L'Intrusion Detection è un sistema che viene utilizzato per rilevare e contrastare gli attacchi informatici che avvengono in un sistema o in una determinata rete. Generalmente un intruso è definito come un sistema, un programma o una persona che tenta di entrare in un sistema di informazione o eseguire un'azione non legalmente consentita.

In particolare in questo esercizio ci concentreremo su quattro tipologie di attacchi:

- -Denial of Service Attacks (DoS): è un tipo di attacco in cui l'hacker rende le risorse di calcolo o di memoria troppo occupate o troppo piene per servire legittime richieste di rete e quindi negare agli utenti l'accesso a una macchina. (es. apache)
- -Remote to User Attacks (R2L): un attacco da remoto a utente è un attacco in cui un utente invia pacchetti a una macchina su Internet, a cui non ha accesso per esporre le vulnerabilità delle macchine e i privilegi di exploit che un utente locale avrebbe sul computer. (es. xlock)
- -User to Root Attacks (U2R): sono exploit in cui l'hacker si avvia sul sistema con un normale account utente e tenta di sfruttare le vulnerabilità nel sistema per ottenere privilegi di super utente. (es. perl)
- **-Probing**: è un attacco in cui l'hacker esegue la scansione di una macchina o di un dispositivo di rete al fine di determinare punti deboli o vulnerabilità che potrebbero essere sfruttati in seguito per compromettere il sistema. Questa tecnica è comunemente usata nel data mining. (es. portsweep)

2 Esperimento

L'esperimento è stato condotto utilizzando il data set della KDD Cup 1999. Questo set di dati è stato fornito dal MIT Lincoln in collaborazione con l'Air Force Lan ed è utile per verificare e utilizzare il classificatore di sistema.

Questo è il set di dati utilizzato per la terza competizione internazionale di scoperta della conoscenza e strumenti di data mining, che si è svolta in concomitanza con la KDD-99. La quinta conferenza internazionale sulla scoperta della conoscenza e il data mining. L'obiettivo della competizione era costruire un rilevatore di intrusione di rete, un modello predittivo in grado di distinguere tra connessioni "cattive", chiamate intrusioni o attacchi e connessioni "buone" normali. Questo database contiene un set standard di dati da verificare, che include un'ampia varietà di intrusioni simulate in un ambiente di rete militare.

L'obiettivo dell'esperimento è quello di riprodurre con maggior accuratezza possibili le tabelle 2 e 3 proposte in (Amor et al.2004).

Table 2: PCC's relative to five classes

TRAINING SET TESTING SET					
Decision tree					
99.99% (99.99%)	92.28% (91.81%)				

Figura 2: Tabella 2 (Amor et al. 2004)

Table 3: Confusion matrices relative to five classes								
Decision tree								
\rightarrow	Normal	DOS	R2L	U2R	Probing			
Normal	99.50%	0.13%	0.01%	0.01%	0.36%			
(60593)	(99.43%)	(0.14%)	(0.02%)	(0.02%)	(0.39%)			
DOS	2.76%	97.24%	0.00%	0.00%	0.00%			
(229853)	(2.94%)	(96.57%)	(0.10%)	(0.00%)	(0.39%)			
R2L	96.55%	0.02%	0.52%	0.15%	2.76%			
(16189)	(75.77%)	(2.79%)	(0.45%)	(4.27%)	(16.71%)			
U2R	79.82%	2.63%	1.75%	7.89%	7.89%			
(228)	(23.25%)	(0.00%)	(5.26%)	(13.60%)	(57.89%)			
Probing	19.54%	5.16%	0.34%	0.00%	74.96%			
(4166)	(15.22%)	(6.67%)	(0.19%)	(0.00%)	(77.92%)			
PCC	92.06% (92.80%)							

Figura 3: Tabella 3 (Amor et al. 2004)

3 Implementazione

Il progetto è stato sviluppato con Python versione 3.7 e richiede l'installazione delle librerie pandas e sklearn.

3.1 preprocessing.py

Nel file preprocessing.py vengono mappate tutte le possibili tipologie di attacchi con l'intero corrispondente. In particolare $Normal\ Attack=0,\ DOS\ Attack=1,\ R2L\ Attack=2,\ U2R\ Attack=3$ e Probinq=4.

Inoltre poichè gli algoritmi di costruzione di un albero di decisione classificano correttamente gli esempi del training set, a condizione che nel training set non siano presenti dati rumorosi. Per far fronte a questa problematica è stata applicata la codifica *one hot* alle variabili categoriche corrispondenti alle colonne *flag*, *protocol_type* e *service*, in modo da ridurre il rumore dei dati.

3.2 dt_predict.py

Nel file dt predict vengono effettuate le predizioni sui dati.

Viene utilizzato DecisionTreeClassifier, preso dalla libreria sklearn che contiene il classificatore basato sugli alberi di decisione. Come criterio di decisione è stato usato entropy, come splitter è stato usato random. Inoltre è stata fissata la massima profondità raggiungibile dall'albero (max_depth=15) e il numero minimo di campioni richiesti in una foglia (min_samples_leaf=6). Questi parametri sono stati scelti in base ai parametri contenuti nella pagina Data Mining Techniques for Intrusion Detection.

3.3 data_names.py

Nel file data_names sono presenti due liste, una contenente i features names e l'altra contente gli attribute names.

3.4 Test

Sono stati effettuati numerosi test, utilizzando le due diverse tipologie di criteri per gli alberi di decisione, entropy e gini, le due diverse tipologie di split, best e random. Sono stati inoltre modificati gli interi assegnati a max_depth e min_samples_leaf, avendo cura di combinare tutte le possibilità.

4 Risultati

Di seguito è riportato il miglior risultato ottenuto dai vari test:

Figura 4: Miglior test effettuato

Riportiamo i dati ottenuti in due distinte tabelle:

TRAINING SET	TESTING SET
99.99%	92.22%

Tabella 1: Dati della Figura 4, riportati in un grafico.

\longrightarrow	Normal	DOS	R2L	U2R	Probing
Normal	98.26%	0.12%	0.0%	0.0%	1.62%
DOS	2.5%	97.44%	0.0%	0.0%	0.07%
R2L	84.82%	0.1%	0.33%	0.01%	14.74%
U2R	91.67%	0.0%	0.0%	6.58%	1.75%
R2L	16.92%	4.61%	0.0%	0.0%	78.47%

Tabella 2: Dati della Figura 4, riportati in un grafico.

5 Conclusione

Dall'analisi del set di dati della KDD Cup 1999, è apparso evidente che erano necessari rivelatori specializzati per classificare i vari tipi di attacchi informatici che avvengono in un sistema o in una rete. Gli attacchi di tipo DoS o Probing si sono dimostrati molto facili da classificare utilizzando modelli semplici. Invece gli attacchi più rari come R2L e U2R necessitano di rivelatori più sofisticati.